

Отчет о работе в семестре по предмету
"Математический практикум"

Алина Терехова

9 декабря 2025 г.

В данной работе производился вывод асимптотики комбинированного метода UniXGraD-DoG + Smoothing technic для оптимизации негладких функций со стохастическим оракулом нулевого порядка с помощью алгоритмов оптимизации гладких функций с оракулами первого порядка.

1 Описание алгоритма UniXGrad-DoG

Схема алгоритма выглядит следующим образом:

Algorithm 1: U-DOG (UNIXGRAD-DOG) template

Input: Initial $x_0 \in \mathcal{K}$, iteration budget T , initial movement r_ϵ , step sizes $\{\eta_{x,t}, \eta_{y,t}\}$

- 1 Set $y_0 = x_0$
- 2 **for** $t = 0, 1, 2, \dots, T - 1$ **do**
- 3 Set $\alpha_t = \sum_{k=0}^t \bar{r}_k / \bar{r}_t$ and $\omega_t = \alpha_t \bar{r}_t$ for $\bar{r}_t = \max_{k \leq t} \max\{\|y_k - x_0\|, \|x_k - x_0\|, r_\epsilon\}$
- 4 $x_{t+1} = \text{Proj}_{\mathcal{K}}(y_t - \alpha_t \eta_{x,t} m_t)$ for $m_t \sim \mathcal{G}(\hat{z}_t)$ and $\hat{z}_t = \frac{\omega_t y_t + \sum_{k=0}^{t-1} \omega_k x_{k+1}}{\sum_{k=0}^t \omega_k}$
- 5 $y_{t+1} = \text{Proj}_{\mathcal{K}}(y_t - \alpha_t \eta_{y,t} g_t)$ for $g_t \sim \mathcal{G}(\hat{x}_t)$ and $\hat{x}_t = \frac{\omega_t x_{t+1} + \sum_{k=0}^{t-1} \omega_k x_{k+1}}{\sum_{k=0}^t \omega_k}$
- 6 **end**
- 7 **return** \hat{x}_T

Рис. 1: UniXGrad-DoG схема

Алгоритм оптимизации работает с выпуклыми, липшицевыми, гладкими функциями, определенными на замкнутом выпуклом множестве и имеющими несмешанный градиент.

Обозначения вводятся следующими:

- L - константа липшицевости
- β - константа гладкости
- \mathcal{K} - замкнутое выпуклое множество, на котором определена f
- \mathcal{G} - стохастический оракул, предоставляющий несмешанный градиент $\mathbb{E}\mathcal{G}(x) = \nabla f(x)$

Поясним принцип действия алгоритма с данных шаблоном:

- На вход схемы подается начальная точка x_0 , сколько максимум итераций можно сделать T , грубая нижняя оценка на расстояние до решения r_ϵ , а также величины шагов для одновременного сдвига двух точек x и y : $\eta_{x,t}$ и $\eta_{y,t}$, которые мы научимся подбирать позднее.
- В начале $y_0 = x_0$. На каждой итерации:
 - Получаем оценку на максимальное удаление от решения $\bar{r}_t = \max_{k \leq t} \max\{\|y_k - x_0\|, \|x_k - x_0\|, r_\epsilon\}$, т.е. это нижняя оценка на диаметр нашего множества.
 - Высчитываем коэффициент $\alpha_t = \sum_{k=0}^t \bar{r}_k / \bar{r}_t$ и вес $w_t = \sum_{k=0}^t \bar{r}_k$. Вес в дальнейшем мы будем использовать, чтобы получать взвешенное среднее всех точек, куда мы когда-либо попадали: так как он возрастает все время, то новые точки вносят больший вклад в подсчет ответа. Коэффициент α_t растет примерно линейно с t по прошествии большого числа итераций. Он используется для того, чтобы уверенней делать шаги со временем.
 - Мы определяем средневзвешенное значение $\hat{z}_t = \frac{\omega_t y_t + \sum_{k=0}^{t-1} \omega_k x_{k+1}}{\sum_{k=0}^t \omega_k}$ точек y_k , и с помощью оценки градиента в этой точке делаем шаг из точки y_t , записывая результат в x_{t+1} . Проекция нужна для того, чтобы случайно не выпрыгнуть за пределы исследуемого множества.
 - То же самое делаем для обновления y_{t+1} . Можно сказать, что y_{t+1} - это оценка на x_{t+2} .

Осталось сказать пару слов про обновление шагов и про ограничения на шум градиента.

Мы работаем далее только со случаем ограниченного множества, так что шаги определяются следующим образом:

$$\eta_{x,t} = \eta_{y,t} = \frac{\bar{r}_t}{\sqrt{1 + Q_{t-1}}}$$

где $Q_{t-1} = \sum_{k=0}^{t-1} \alpha_k^2 \|g_t - m_t\|^2$ - оценка того, насколько шумно сейчас выдается градиент. Чем выше эта величина, тем меньше делается шаг.

Что касается шума, мы анализируем ситуацию, когда он ограничен сверху некоторой константой σ , т.е. $\|\mathcal{G}(x) - \nabla f(x)\| \leq \sigma$. Со всеми введенными обозначениями в аппендиаксе статьи выводится асимптотика:

$$\tilde{O}\left(\frac{\beta d_0^2}{T^2} + \frac{\sigma d_0}{\sqrt{T}}\right)$$

для скорости сходимости алгоритма (так как мы имеем дело со случаем ограниченного множества, тут d_0 означает нижнюю оценку на его диаметр)

2 Описание Smoothing scheme

Пусть у нас имеется задача оптимизации функции f на выпуклом множестве Q . Сама функция f выпукла на множестве $Q_\gamma = Q + B_2^d(\gamma)$, где последнее слагаемое - это евклидов шар радиуса γ с центром в нуле. Далее, мы делаем следующие предположения:

- Функция f - липшицева на Q_γ . Обозначим константу, для совместности с предыдущей статьей, как L . (при этом она липшицева по p -норме; если $p=2$ обозначим константу за L_2)
- У нас есть оракул нулевого порядка, выдающий значение функции с некоторым ограниченным шагом Δ .

Из этих предположений выводятся следующие утверждения для слаженной функции $f_\gamma = \mathbb{E}f(x+u)$, где u - случайный вектор, равномерно распределенный в шаре $B_2^d(\gamma)$. Оговоримся, что градиент данной функции аппроксимируется, как $\nabla f_\gamma(x, e) = \frac{d}{2\gamma} \frac{f(x+\gamma e) - f(x-\gamma e)}{2\gamma} e$, где e - случайный вектор, равномерно распределенный по сфере единичного радиуса с центром в нуле.

- f_γ - L -липшицева на Q_γ по норме p

- f_γ - гладкая с константой $\beta = \frac{\sqrt{d}L}{\gamma}$, где $\frac{1}{q} + \frac{1}{p} = 1$

$$\|\nabla f_\gamma(y) - \nabla f_\gamma(x)\|_q \leq \beta \|x - y\|_p \quad (1)$$

- Для аппроксимации градиента f_γ справедливо:

$$\sigma^2 = \mathbb{E}_e[\|\nabla f(x, e)\|_q^2] \leq \kappa(p, d)(dM_2^2 + \frac{d^2\Delta^2}{\gamma^2}) \quad (2)$$

где $\kappa(p, d) = O(\min\{q, \ln d\}d^{\frac{d}{q-1}})$, d - размерность пространства, откуда действует f .

Теперь опишем суть метода.

Пусть у нас есть алгоритм $\mathbf{A}(\beta, \sigma^2)$, который решает задачу оптимизации функции f на Q_γ , которая одновременно:

- Гладкая с константой β и для нее выполнено $\forall x, y \in Q_\gamma$

$$\|\nabla f(x) - \nabla f(y)\|_q \leq \beta \|x - y\|_p$$

- Имеет стохастический оракул 1-го порядка, который зависит от случайной величины η и выдает несмешанный градиент с ограниченной дисперсией:

$$\mathbb{E}_\eta[\|\nabla_x f(x, \eta) - \nabla f(x)\|] \leq \sigma^2$$

т.е. выполнено (2)

Идея в том, чтобы использовать этот алгоритм для оптимизации функции f_γ с $\gamma = \frac{\varepsilon}{2L_2}$, $\eta = e$, $\nabla_x f(x, \eta) = \nabla_\gamma f(x, e)$. Таким образом, мы получим алгоритм оптимизации негладкой стохастической функции с оракулом нулевого порядка.

Если алгоритм \mathbf{A} требовал $N(\beta, \varepsilon)$ успешных итераций и $T(\beta, \sigma^2, \varepsilon)$ вызовов стохастического оракула 1-го порядка, то для решения новой задачи потребуется:

$$N\left(\frac{2\sqrt{d}LL_2}{\varepsilon}, \varepsilon\right)$$

$$2T\left(\frac{2\sqrt{d}LL_2}{\varepsilon}, 2\kappa(p, d)dM_2^2, \varepsilon\right)$$

3 Изменения в доказательстве асимптотики U-DoG

Поскольку далее в работе нам потребуется оценка на матожидание $f(\hat{x}_t) - f(x^*)$, получим его, используя доказательство асимптотики U-DoG.

Возьмем матожидание от следующего выражения:

$$\begin{aligned} f(\hat{x}_t) - f(x^*) &\leq 360s^{3/2} \frac{\beta(\bar{r}_{t+1} + \bar{d}_{t+1})^2}{(\sum_{k=0}^t \bar{r}_k / \bar{r}_{t+1})^2} \\ &+ 10 \frac{(\bar{r}_{t+1} + \bar{d}_{t+1})(\sqrt{\max\{G_{y,t}, Q_t\}} - s\sqrt{Q_t})}{(\sum_{k=0}^t \bar{r}_k / \bar{r}_{t+1})^2} \\ &+ 20 \frac{(\bar{r}_{t+1} + \bar{d}_{t+1})\sqrt{(t+1)^3 V_t + (\theta_{t+1,\delta}\sigma)^2}}{(\sum_{k=0}^t \bar{r}_k / \bar{r}_{t+1})^2} \end{aligned}$$

Здесь три слагаемых, следовательно, в силу линейности матожидания:

$$\mathbb{E}[f(\hat{x}_t) - f(x^*)] \leq \mathbb{E}[A] + \mathbb{E}[B] + \mathbb{E}[C]$$

Разберем по порядку:

1) A

$$\mathbb{E}[A] = 360s^{3/2}\beta \cdot \mathbb{E}\left[\frac{(\bar{r}_{t+1} + \bar{d}_{t+1})^2}{(\sum_{k=0}^t \bar{r}_k / \bar{r}_{t+1})^2}\right]$$

Заметим, что $\bar{r}_{t+1} + \bar{d}_{t+1} \leq 6d_0$

$$\mathbb{E}[A] \leq 360s^{3/2}\beta \cdot 36d_0^2 \cdot \mathbb{E}\left[\frac{1}{(\sum_{k=0}^t \bar{r}_k / \bar{r}_{t+1})^2}\right]$$

Знаменатель ведет себя, как $\Omega(\frac{t^2}{\log^2 t})$

$$\mathbb{E}[A] \leq 360s^{3/2}\beta \cdot 36d_0^2 \cdot O\left(\frac{\log^2 t}{t^2}\right) = O\left(\frac{s^{3/2}\beta d_0^2 \log^2 t}{t^2}\right)$$

2) B

$$\mathbb{E}[B] = 10\mathbb{E}\left[\frac{(\bar{r}_{t+1} + \bar{d}_{t+1})(\sqrt{\max\{G_{y,t}, Q_t\}} - s\sqrt{Q_t})}{(\sum_{k=0}^t \bar{r}_k / \bar{r}_{t+1})^2}\right] \leq 60d_0\mathbb{E}\left[\frac{\sqrt{\max\{G_{y,t}, Q_t\}} - s\sqrt{Q_t}}{(\sum_{k=0}^t \bar{r}_k / \bar{r}_{t+1})^2}\right]$$

Заметим, что знаменатель вновь есть $\Omega(\frac{t^2}{\log^2 t})$. Проанализируем числитель. Заметим, что в случае ограниченного множества, на котором исследуется функция: $G_{y,t} = 1 + Q_t$, таким образом:

$$\sqrt{\max\{G_{y,t}, Q_t\}} - s\sqrt{Q_t} = \sqrt{1 + Q_t} - s\sqrt{Q_t} \leq (1-s)\sqrt{1 + Q_t} \leq (1-s)\sqrt{1 + \sigma^2 t \alpha_t^2} = O((1-s)\sigma\sqrt{t}\alpha_t)$$

Подставим всё в предыдущее соотношение:

$$\mathbb{E}[B] \leq 60d_0 \cdot O\left(\frac{(1-s)\sigma \log t}{\sqrt{t}}\right) = O\left(\frac{(1-s)\sigma d_0 \log t}{\sqrt{t}}\right)$$

3) C

$$\mathbb{E}[C] = 20\mathbb{E}\left[\frac{(\bar{r}_{t+1} + \bar{d}_{t+1})\sqrt{(t+1)^3 V_t + (\theta_{t+1,\delta}\sigma)^2}}{(\sum_{k=0}^t \bar{r}_k / \bar{r}_{t+1})^2}\right] \leq 120d_0\mathbb{E}\left[\frac{\sqrt{(t+1)^3 V_t + (\theta_{t+1,\delta}\sigma)^2}}{(\sum_{k=0}^t \bar{r}_k / \bar{r}_{t+1})^2}\right]$$

Вновь проанализируем числитель. Заметим, что так как шум мы считаем ограниченным, то $V_t \leq 2\sigma^2$.

$$\sqrt{O(t^3\sigma^2 + \sigma \log^2 \log t)} = O(t^{\frac{3}{2}}\sigma + \sqrt{\sigma} \log \log t)$$

Тогда для всего выражения:

$$\mathbb{E}[C] \leq O\left(\frac{d_0\sigma \log^2 t}{\sqrt{t}} + \frac{d_0\sqrt{\sigma} \log^2 t \log \log t}{t^2}\right)$$

Собираем все вместе и получаем:

$$\mathbb{E}[f(\hat{x}_t) - f(x^*)] \leq O\left(\frac{s^{3/2}\beta d_0^2 \log^2 t}{t^2} + \frac{(1-s)\sigma d_0 \log t}{\sqrt{t}} + \frac{d_0\sigma \log^2 t}{\sqrt{t}} + \frac{d_0\sqrt{\sigma} \log^2 t \log \log t}{t^2}\right)$$

4 Вывод асимптотики комбинированного метода

Мы имеем:

$$\mathbb{E}[f(\hat{x}_t) - f(x^*)] \leq O\left(\frac{s^{3/2}\beta d_0^2 \log^2 t}{t^2} + \frac{(1-s)\sigma_B d_0 \log t}{\sqrt{t}} + \frac{d_0 \sigma_B \log^2 t}{\sqrt{t}} + \frac{d_0 \sqrt{\sigma_B} \log^2 t \log \log t}{t^2}\right)$$

Это дает для некоторых констант:

$$\mathbb{E}[f(\hat{x}_t) - f(x^*)] \leq C_1\left(\frac{(1-s)\sigma_B d_0 \log t}{\sqrt{t}} + \frac{d_0 \sigma_B \log^2 t}{\sqrt{t}}\right) + C_2\left(\frac{s^{3/2}\beta d_0^2 \log^2 t}{t^2} + \frac{d_0 \sqrt{\sigma_B} \log^2 t \log \log t}{t^2}\right)$$

Для того, чтобы все решение было менее $\frac{\varepsilon}{2}$ достаточно требовать, чтобы каждое из слагаемых не превосходило $\frac{\varepsilon}{4}$. Запишем это условие и оценим значения N и B для такой точности:

$$C_1\left(\frac{(1-s)\sigma_B d_0 \log N}{\sqrt{N}} + \frac{d_0 \sigma_B \log^2 N}{\sqrt{N}}\right) \leq \frac{\varepsilon}{4} \Rightarrow \sqrt{N} \geq \frac{4C_1 d_0 \sigma_B \log N (1-s + \log N)}{\varepsilon}$$

Подставим σ_B :

$$\sqrt{N} \geq \frac{4C_1 d_0 \sigma \sqrt{\lambda(p, d)} \log N (1-s + \log N)}{\sqrt{B} \varepsilon}$$

Заметим, что $\exists N_0 : \forall N \geq N_0$ выполнено $\log N \geq \log \frac{16C_1^2 d_0^2 \sigma^2}{\varepsilon^2 B}$

$$\Rightarrow N \geq \frac{16C_1^2 d_0^2 \sigma^2 \lambda(p, d) \log \frac{16C_1^2 d_0^2 \sigma^2}{\varepsilon^2 B} (1-s + \log \frac{16C_1^2 d_0^2 \sigma^2}{\varepsilon^2 B})^2}{\varepsilon^2 B}$$

С другой стороны, из второго слагаемого получаем:

$$C_2\left(\frac{s^{3/2}\beta d_0^2 \log^2 t}{t^2} + \frac{d_0 \sqrt{\sigma_B} \log^2 t \log \log t}{t^2}\right) \leq \frac{\varepsilon}{4} \Rightarrow N^2 \geq 4C_2 \frac{d_0 \log^2 N}{\varepsilon} (s^{3/2}\beta d_0 + \sqrt{\sigma_B} \log \log N)$$

То же самое рассуждение применимо тут: $\exists N_0 : \forall N \geq N_0 \log N \geq \log \frac{d_0}{\varepsilon}$ и подставим σ_B :

$$N^2 \geq 4C_2 \frac{d_0 \log^2 \frac{d_0}{\varepsilon}}{\varepsilon} (s^{3/2}\beta d_0 + \sqrt{\sigma} \frac{\lambda(p, q)^{1/4}}{B^{1/4}} \log \log \frac{d_0}{\varepsilon})$$

$$N \geq 2C_2^{1/2} \frac{d_0^{1/2} \log \frac{d_0}{\varepsilon}}{\varepsilon^{1/2}} (s^{3/2}\beta d_0 + \sqrt{\sigma} \frac{\lambda(p, q)^{1/4}}{B^{1/4}} \log \log \frac{d_0}{\varepsilon})^{1/2}$$

Значит, итоговая оценка на N будет максимумом из этих двух величин:

$$N \geq \max\left\{2C_2^{1/2} \frac{d_0^{1/2} \log \frac{d_0}{\varepsilon}}{\varepsilon^{1/2}} (s^{3/2}\beta d_0 + \sqrt{\sigma} \frac{\lambda(p, q)^{1/4}}{B^{1/4}} \log \log \frac{d_0}{\varepsilon})^{1/2}, \frac{16C_2^2 d_0^2 \sigma^2 \lambda(p, d) \log \frac{16C_1^2 d_0^2 \sigma^2}{\varepsilon^2 B} (1-s + \log \frac{16C_1^2 d_0^2 \sigma^2}{\varepsilon^2 B})^2}{\varepsilon^2 B}\right\}$$

Получим оценку на B . Для начала рассмотрим второй элемент максимума:

$$N \geq \frac{K_1 \log \frac{A}{B} (K_2 + \log \frac{A}{B})^2}{B} \geq \frac{K_1 (\log \frac{A}{B})^3}{B}$$

Второй элемент:

$$N \geq P_1 (P_2 + \frac{P_3}{B^{1/4}})^{1/2} \geq \frac{P_1 P_3^{1/2}}{B^{1/8}}$$

Балансировка:

$$\frac{P_1 P_3^{1/2}}{B^{1/8}} = \frac{K_1 (\log \frac{A}{B})^3}{B} \Rightarrow B^{7/8} = \frac{K_1}{P_1 P_3^{1/2}} (\log \frac{A}{B})^3 \leq \frac{K_1}{P_1 P_3^{1/2}} (\log A)^3$$

$$B^{7/8} \leq \frac{8C_1^2 d_0^{3/2} \sigma^{7/4} \lambda^{7/8}(p, d)}{C_2^{1/2} \log \frac{d_0}{\varepsilon} (\log \log \frac{d_0}{\varepsilon})^{1/2} \varepsilon^{3/2}} \Rightarrow B = \tilde{O}\left(\frac{d_0^{12/7} \sigma^2}{\varepsilon^{12/7}}\right)$$

Значит, для числа итераций:

$$N \geq \max\left\{\tilde{O}\left(\frac{d_0^{1/2}}{\varepsilon^{1/2}} (s^{3/2}\beta d_0 + \frac{\sigma^{1/2}}{B^{1/4}})^{1/2}\right), \tilde{O}\left(\frac{d_0^2 \sigma^2}{\varepsilon^2 B}\right)\right\}$$

$$N \geq \max\{\tilde{O}(T_1), \tilde{O}(T_2)\}$$

$$\begin{aligned} T_1 &= \frac{d_0^{1/2}}{\varepsilon^{1/2}} (s^{3/2} \beta d_0 + \frac{\varepsilon^{3/7}}{d_0^{3/7}})^{1/2} = \sqrt{\frac{s^{3/2} \beta d_0^2}{\varepsilon} + (\frac{d_0}{\varepsilon})^{4/7}} \\ T_2 &= (\frac{d_0}{\varepsilon})^{2/7} \end{aligned}$$

Заметим, что $T_2 \leq T_1$ при любых значениях входящих переменных (т.к. все они положительны)

$$N = \tilde{\Omega}\left(\sqrt{\frac{s^{3/2} \beta d_0^2}{\varepsilon} + (\frac{d_0}{\varepsilon})^{4/7}}\right) = \tilde{\Omega}\left(\frac{s^{3/4} \beta^{1/2} d_0}{\sqrt{\varepsilon}}\right)$$

Подставим оценку $\beta = \frac{\sqrt{d}L}{\gamma} = \frac{2d^{1/2}LL_2}{\varepsilon}$

$$N = \tilde{\Omega}\left(\frac{s^{3/4} d^{1/4} \sqrt{LL_2}}{\varepsilon} d_0\right)$$

Тогда оценка для числа оракульных вызовов:

$$T = N \cdot B = \tilde{\Omega}\left(\frac{s^{3/4} d^{1/4} L^{1/2} L_2^{1/2} d_0^{19/7} \sigma^2}{\varepsilon^{19/7}}\right)$$

5 Анализ осимптотики

В ходе работы была проанализирована асимптотика комбинированного метода UniXGraD-DoG и Smoothing schene. Полученная оценка на число итераций выглядит правдоподобно по сравнению с данными, характерными для задач рассматриваемого класса, однако оценка на размер батча требует более тщательной проверки. Дальнейший этап работы - это попытаться протестировать реальные функции и посмотреть на реальные зависимости для размера батча. Сравнение их с теоретически полученными позволит проверить корректность расчетов.